Taller 02 – Aprendizaje Supervisado

Parte 01: Evaluación Conceptual (Quiz)

Curso: Inteligencia Artificial ECA&I (Posgrado) **Docente:** Jorge Iván Padilla-Buriticá
Universidad EAFIT – Periodo 2026-1

Instrucciones: Para cada una de las 20 preguntas se selecciona la respuesta correcta y se justifica brevemente (máximo 3 líneas) desde la teoría estadística y computacional.

Preguntas y Respuestas

Pregunta 1

En un modelo de regresión lineal, si el valor del estadístico R^2 es 0.95, pero el error en el conjunto de prueba es significativamente mayor que en el de entrenamiento, estamos ante:

a) Underfitting (Subajuste).

b) **Overfitting (Sobreajuste).**

c) Sesgo (Bias) alto.

d) Error irreducible.

Respuesta correcta: b) Overfitting (Sobreajuste)

Un $R^2 = 0{,}95$ sobre el conjunto de entrenamiento indica que el modelo explica casi toda la varianza de esos datos*, pero el error notablemente mayor en prueba delata que el modelo memorizó patrones específicos del entrenamiento en lugar de generalizar. Esta brecha entre error de entrenamiento y de prueba es la definición canónica del sobreajuste.*

Pregunta 2

La principal diferencia entre el Aprendizaje Supervisado y el No Supervisado es:

a) El uso de algoritmos de optimización.

b) **La presencia de una variable objetivo (*label*) conocida.**

c) La cantidad de datos necesarios.

d) La capacidad de procesar imágenes.

Respuesta correcta: b) La presencia de una variable objetivo conocida

En aprendizaje supervisado, el algoritmo aprende la función $f : \mathcal{X} \to \mathcal{Y}$ a partir de pares $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ con etiquetas conocidas. El aprendizaje no supervisado, en cambio, trabaja con datos sin etiquetas, buscando estructura latente (clusters, componentes principales, etc.) sin una señal de corrección explícita.

Pregunta 3

Al evaluar un clasificador para detectar enfermedades raras (clases desbalanceadas), ¿qué métrica es más informativa que el *Accuracy*?

a) Error Cuadrático Medio (MSE).

b) Coeficiente de Determinación.

c) **F1-Score o Precision-Recall AUC.**

d) Desviación estándar de los residuos.

Respuesta correcta: c) F1-Score o Precision-Recall AUC

Con clases muy desbalanceadas, un clasificador que siempre predice la clase mayoritaria puede alcanzar un accuracy alto sin detectar ningún caso positivo real. El F1-Score, media armónica de Precisión y Recall, y el área bajo la curva Precision-Recall penalizan directamente los falsos negativos y falsos positivos, siendo métricas mucho más informativas en escenarios de detección de enfermedades raras.

Pregunta 4

En validación cruzada (K-Fold Cross Validation), si $K = N$ (donde N es el número de muestras), el método se conoce como:

a) Bootstrap.

b) Stratified K-Fold.

c) **Leave-One-Out Cross-Validation (LOOCV).**

d) Validación por *hold-out*.

Respuesta correcta: c) Leave-One-Out Cross-Validation (LOOCV)

Cuando $K = N$, en cada iteración el modelo entrena sobre $N - 1$ muestras y valida sobre la única muestra restante, que "se deja fuera"(leave one out). Este proceso se repite N veces, produciendo un estimador casi insesgado del error de generalización, aunque computacionalmente costoso para datasets grandes.

Pregunta 5

La función de pérdida *Log-Loss* (o Entropía Cruzada) es comúnmente utilizada para:

a) Regresión lineal multivariada.

b) **Clasificación probabilística.**

c) *Clustering* de K-medias.

d) Reducción de dimensionalidad PCA.

Respuesta correcta: b) Clasificación probabilística

La entropía cruzada binaria $\mathcal{L} = -\frac{1}{N}\sum_i [y_i \log \hat{p}_i + (1 - y_i)\log(1 - \hat{p}_i)]$ *cuantifica la discrepancia entre la distribución predicha y la distribución verdadera de las clases. Es la función de pérdida natural de la regresión logística y de redes neuronales de clasificación, pues su gradiente impulsa al modelo a asignar probabilidades altas a las clases correctas.*

Pregunta 6

Respecto al *Trade-off* entre Sesgo (Bias) y Varianza:

a) Modelos complejos tienden a tener alto sesgo y baja varianza.

b) El error total se minimiza aumentando la varianza indefinidamente.

c) **Modelos muy simples suelen presentar alto sesgo y baja varianza.**

d) No existe relación entre la complejidad y el error.

Respuesta correcta: c) Modelos muy simples → alto sesgo y baja varianza

La descomposición del error cuadrático esperado es $Error = Sesgo^2 + Varianza + Error\ irreducible$. *Un modelo simple (ej. regresión lineal en un problema no lineal) tiene alta capacidad de error sistemático (sesgo) pero cambia poco ante distintos conjuntos de entrenamiento (baja varianza). Los modelos complejos presentan el comportamiento contrario: bajo sesgo, alta varianza.*

Pregunta 7

¿Para qué sirve la técnica de Regularización L2 (Ridge) en regresión?

a) Para eliminar variables haciendo sus coeficientes exactamente cero.

b) **Para penalizar la magnitud de los coeficientes y evitar el sobreajuste.**

c) Para aumentar la complejidad del modelo.

d) Para normalizar los datos entre 0 y 1.

Respuesta correcta: b) Penalizar la magnitud de los coeficientes

Ridge añade el término $\lambda\|\mathbf{w}\|_2^2$ *a la función de pérdida:* $\mathcal{L}_{Ridge} = MSE + \lambda \sum_j w_j^2$. *Esto encoge los coeficientes hacia cero sin anularlos exactamente, reduciendo la varianza del modelo a expensas de un ligero incremento en el sesgo.A diferencia de Lasso (L1), Ridge retiene todas las variables en el modelo.*

Pregunta 8

El área bajo la curva ROC (AUC-ROC) mide:

a) La precisión exacta en el punto de corte 0.5.

b) **La capacidad del modelo para distinguir clases independientemente del umbral.**

c) El error promedio de las predicciones continuas.

d) La correlación entre las características de entrada.

Respuesta correcta: b) Distinguir clases independientemente del umbral

El AUC-ROC equivale a la probabilidad de que el modelo asigne un score más alto a una instancia positiva seleccionada al azar que a una negativa: $AUC = P(\hat{p}(x^+) > \hat{p}(x^-))$. *Al integrar sobre* todos *los posibles umbrales de clasificación, es una métrica de ranking que no depende de un corte fijo, lo que la hace robusta a desbalance de clases.*

Pregunta 9

En clasificación, una matriz de confusión permite identificar específicamente:

a) Los hiperparámetros óptimos.

b) El tiempo de ejecución del entrenamiento.

c) **Falsos Positivos, Falsos Negativos, Verdaderos Positivos y Negativos.**

d) La importancia de las características.

Respuesta correcta: c) TP, TN, FP y FN

La matriz de confusión organiza las predicciones en una tabla de contingencia: Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN). A partir de estas cuatro cantidades se derivan métricas como Precisión $= TP/(TP + FP)$, *Recall* $= TP/(TP + FN)$ *y F1-Score, ofreciendo una visión detallada de los errores del clasificador.*

Pregunta 10

El fenómeno de la "Maldición de la Dimensionalidad" implica que:

a) A más dimensiones, más fácil es encontrar patrones.

b) **El volumen del espacio crece exponencialmente, haciendo los datos dispersos.**

c) El rendimiento siempre mejora con más variables.

d) Los datos se vuelven más densos.

Respuesta correcta: b) Volumen crece exponencialmente → datos dispersos

En un hiper-cubo unitario de dimensión d, el volumen es $1^d = 1$, pero para capturar una fracción f de los datos con una hiper-esfera, el radio necesario escala como $r \propto f^{1/d}$: conforme $d \to \infty$, los puntos se vuelven equidistantes y los algoritmos basados en vecindad (KNN, kernels) pierden poder discriminativo.

Pregunta 11

¿Cuál es la principal ventaja de utilizar *Stochastic Gradient Descent* (SGD) sobre el *Batch Gradient Descent*?

a) Garantiza alcanzar siempre el mínimo global.

b) **Es computacionalmente más eficiente en conjuntos de datos masivos.**

c) Reduce la varianza de las actualizaciones del modelo.

d) No requiere escalar las características.

Respuesta correcta: b) Más eficiente en datasets masivos

El GD por lotes (batch) requiere calcular el gradiente sobre todos *los N ejemplos en cada paso, con coste $O(N)$ por iteración. SGD actualiza los parámetros tras procesar un único ejemplo (o un mini-batch), reduciendo el coste por iteración a $O(1)$ o $O(B)$, permitiendo aprender de forma incremental en datasets que no caben en memoria y convergiendo más rápido en la práctica.*

Pregunta 12

El uso de *StandardScaler* (Z-score normalization) es crítico en algoritmos basados en distancias como:

a) Árboles de Decisión.

b) **K-Nearest Neighbors (KNN) y SVM.**

c) Naive Bayes.

d) Random Forest.

Respuesta correcta: b) KNN y SVM

KNN y SVM calculan distancias euclidianas o kernels directamente sobre los valores de las características; si una variable tiene escala 10^3 y otra 10^{-1}, la primera dominará artificialmente la distancia. StandardScaler transforma $x' = (x-\mu)/\sigma$, poniendo todas las variables en la misma escala. Los árboles de decisión y Random Forest, en cambio, usan umbrales univariados y son invariantes a transformaciones monótonas.

Pregunta 13

La Regularización L1 (Lasso) se diferencia de L2 (Ridge) principalmente porque:

a) L1 siempre produce mejores predicciones.

b) **L1 puede realizar selección de características al llevar coeficientes a cero.**

c) L2 es más propensa al *overfitting*.

d) No existe diferencia matemática real.

Respuesta correcta: b) L1 produce soluciones sparse

Lasso penaliza la norma L1: $\lambda \sum_j |w_j|$. Geométricamente, la región de restricción L1 tiene vértices en los ejes coordenados, lo que hace probable que la solución óptima toque uno de esos vértices, anulando exactamente algunos coeficientes y realizando selección implícita de variables. Ridge ($\|\mathbf{w}\|_2^2$) tiene una región esférica; solo encoge los coeficientes pero no los lleva a cero exactamente.

Pregunta 14

¿Qué indica una curva de aprendizaje donde tanto el error de entrenamiento como el de validación son altos y cercanos entre sí?

a) El modelo sufre de alta varianza (Overfitting).

b) **El modelo sufre de alto sesgo (Underfitting).**

c) El modelo ha alcanzado la convergencia óptima.

d) Se necesitan menos datos de entrenamiento.

Respuesta correcta: b) Alto sesgo (Underfitting)

Cuando ambas curvas de error (entrenamiento y validación) son altas y convergen a un valor similar, el modelo no tiene suficiente capacidad para capturar los patrones del problema: hay alto sesgo. Si hubiese alta varianza (overfitting), el error de entrenamiento sería bajo y el de validación alto, evidenciando la brecha característica.

Pregunta 15

En el contexto de *Random Forest*, el concepto de "OOB Error" (*Out-of-Bag*) se utiliza para:

a) Medir el tiempo de poda de los árboles.

b) **Estimar el error de generalización sin un conjunto de validación externo.**

c) Calcular la profundidad máxima de cada árbol.

d) Normalizar los pesos de los clasificadores débiles.

Respuesta correcta: b) Estimador interno de error de generalización

Random Forest construye cada árbol con un subconjunto bootstrap (63 % de los datos). El 37 % restante (los ejemplos "fuera de la bolsa" (OOB)) no participa en el entrenamiento de ese árbol y puede usarse para evaluarlo directamente. Promediando las predicciones OOB de todos los árboles se obtiene un estimador del error de generalización que equivale aproximadamente a una validación cruzada leave-one-out.

Pregunta 16

¿Cuál es el propósito del parámetro de "Kernel" en una *Support Vector Machine* (SVM)?

a) Reducir el número de vectores de soporte.

b) **Proyectar datos a un espacio de mayor dimensión para buscar separabilidad lineal.**

c) Acelerar el proceso de gradiente descendente.

d) Limpiar los valores atípicos del *dataset*.

Respuesta correcta: b) Proyectar a espacio de mayor dimensión (*kernel trick*)

El kernel trick permite calcular el producto interno en un espacio de características de alta (o infinita) dimensión sin mapear explícitamente los datos: $k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$. *Kernels como RBF* ($\exp(-\gamma\|\mathbf{x} - \mathbf{x}'\|^2)$) *crean fronteras no lineales en el espacio original, permitiendo separabilidad lineal en el espacio transformado a un coste computacional manejable.*

Pregunta 17

En un problema de clasificación multiclase, la estrategia "One-vs-Rest" (OvR):

a) Entrena un único modelo para todas las clases simultáneamente.

b) **Entrena un clasificador binario por cada clase frente a todas las demás.**

c) Compara cada par posible de clases individualmente.

d) Solo funciona con redes neuronales profundas.

Respuesta correcta: b) Un clasificador binario por clase

Con C clases, OvR entrena C clasificadores binarios. El k-ésimo clasificador distingue "clase k" vs. "todas las demás clases". En inferencia, se aplican los C modelos y se asigna la clase cuyo clasificador devuelve la probabilidad más alta. Es una estrategia simple y eficiente que extiende cualquier clasificador binario a problemas multiclase.

Pregunta 18

La métrica MAE (*Mean Absolute Error*) es preferible sobre MSE (*Mean Squared Error*) cuando:

a) Se desea penalizar fuertemente los errores grandes (*outliers*).

b) **Se busca una métrica más robusta y menos sensible a valores atípicos.**

c) La variable objetivo sigue una distribución normal perfecta.

d) No hay diferencia, ambas miden lo mismo.

Respuesta correcta: b) Más robusta a valores atípicos

$MAE = \frac{1}{N}\sum_i |y_i - \hat{y}_i|$ penaliza todos los errores linealmente, mientras que $MSE = \frac{1}{N}\sum_i (y_i - \hat{y}_i)^2$ eleva los errores al cuadrado, amplificando desproporcionadamente el impacto de los outliers. Cuando los datos contienen valores atípicos que no representan el comportamiento típico, MAE es preferible porque no castiga excesivamente esos casos extremos.

Pregunta 19

¿Qué técnica ayuda a combatir el *Data Leakage* (Fuga de datos)?

a) **Realizar el escalamiento de datos (*fit*) solo sobre el conjunto de entrenamiento.**

b) Usar todas las variables disponibles en el *dataset* original sin filtrar.

c) Entrenar el modelo con los datos de prueba incluidos.

d) Imputar valores faltantes usando la media de todo el *dataset* antes de dividir.

Respuesta correcta: a) Fit del scaler/imputer solo sobre datos de entrenamiento

Cuando se ajusta un `StandardScaler` o un imputer sobre el dataset completo (incluyendo test), los estadísticos (μ, σ, mediana) se calculan con información del futuro, filtrando datos del conjunto de prueba hacia el entrenamiento. La práctica correcta

es: `scaler.fit(X_train)` → `transform(X_train)` → `transform(X_test)`*, garantizando que el modelo no "ve"los datos de prueba durante ninguna etapa del preprocesamiento.*

Pregunta 20

El algoritmo XGBoost se basa en la técnica de:

a) Bagging (muestreo con reemplazo).

b) **Boosting (entrenamiento secuencial para corregir errores previos).**

c) Stacking (combinación de modelos heterogéneos).

d) Clustering jerárquico.

Respuesta correcta: b) Boosting secuencial

XGBoost (eXtreme Gradient Boosting) es una implementación optimizada de Gradient Boosted Trees: en cada iteración t se entrena un árbol de decisión $h_t(\mathbf{x})$ que modela los residuos (pseudo-gradientes) del ensamble acumulado $F_{t-1}(\mathbf{x})$, de modo que $F_t = F_{t-1} + \eta \cdot h_t$. A diferencia del Bagging (ej. Random Forest), los árboles se construyen secuencialmente*, corrigiendo los errores de los modelos anteriores.*

Tabla Resumen de Respuestas

Pregunta	Respuesta	Concepto clave
1	b	Overfitting
2	b	Variable objetivo (label)
3	c	F1-Score / Precision-Recall AUC
4	c	Leave-One-Out CV (LOOCV)
5	b	Clasificación probabilística
6	c	Alto sesgo (underfitting)
7	b	Regularización Ridge (shrinkage)
8	b	AUC-ROC independiente del umbral
9	c	TP, TN, FP, FN
10	b	Maldición de la dimensionalidad
11	b	SGD eficiente en datos masivos
12	b	KNN y SVM (distancias)
13	b	Lasso $\rightarrow$ coeficientes esparcidos
14	b	Alto sesgo (ambos errores altos)
15	b	OOB como validación interna
16	b	Kernel trick en SVM
17	b	One-vs-Rest: C clasificadores binarios
18	b	MAE robusto a outliers
19	a	Fit solo en conjunto de entrenamiento
20	b	Boosting secuencial (XGBoost)

"In God we trust, all others must bring data." — W. Edwards Deming